

# Practica\_PLN\_Grupo08

2025-12-05

## Práctica 8

CUIDADO AL EJECUTAR (Limpia el Global Enviroment)

```
rm(list = ls())
```

### 1º Parte

Lectura del archivo 10000 palabras

```
# Leer el archivo
lineas <- readLines("10000_formas_ortograficas.txt",
                     encoding = "UTF-8")
lineas[0:4]

## [1] "Forma\tFrecuencia\tFrec. norm. " ",\t27823866\t56483.65"
## [3] "de\t26286396\t53362.52"           ".\t19226627\t39030.88"

# Buscar donde empieza la priemra linea
linea_inicio <- grep("^[^0-9\t\n]+\t[0-9]+\t[0-9]+", lineas)[1]

# Extraer 10000 lineas a partir del inicio
datos <- lineas[linea_inicio:(linea_inicio + 9999)]

# Separar cada linea por tabulador (\t)
partes <- strsplit(datos, "\t")
partes[0:4]

## [[1]]
## [1] "27823866" "56483.65"
##
## [[2]]
## [1] "26286396" "53362.52"
##
## [[3]]
## [1] "19226627" "39030.88"
##
## [[4]]
## [1] "15799962" "32074.6"
```

```

# Extraer las columnas
formas <- sapply(partes, function(x) x[1])
frecuencias <- as.numeric(sapply(partes, function(x) x[2]))
frec_norm <- as.numeric(sapply(partes, function(x) x[3]))

# Crear el dataframe
tabla <- data.frame(Forma = formas,
                      Frecuencia = frecuencias,
                      Frec.norm = frec_norm,
                      stringsAsFactors = FALSE)
head(tabla)

##      Forma Frecuencia Frec.norm
## 1      ,    27823866   56483.65
## 2     de    26286396   53362.52
## 3     .    19226627   39030.88
## 4     la    15799962   32074.60
## 5     que   13350795   27102.69
## 6     y    11562228   23471.82

tail(tabla)

##           Forma Frecuencia Frec.norm
## 9995     militancia    3422     6.94
## 9996     perciben    3421     6.94
## 9997     católico    3421     6.94
## 9998     convertía    3421     6.94
## 9999 especialización 3421     6.94
## 10000    golpeó     3421     6.94

```

## Ley de Zipf

```

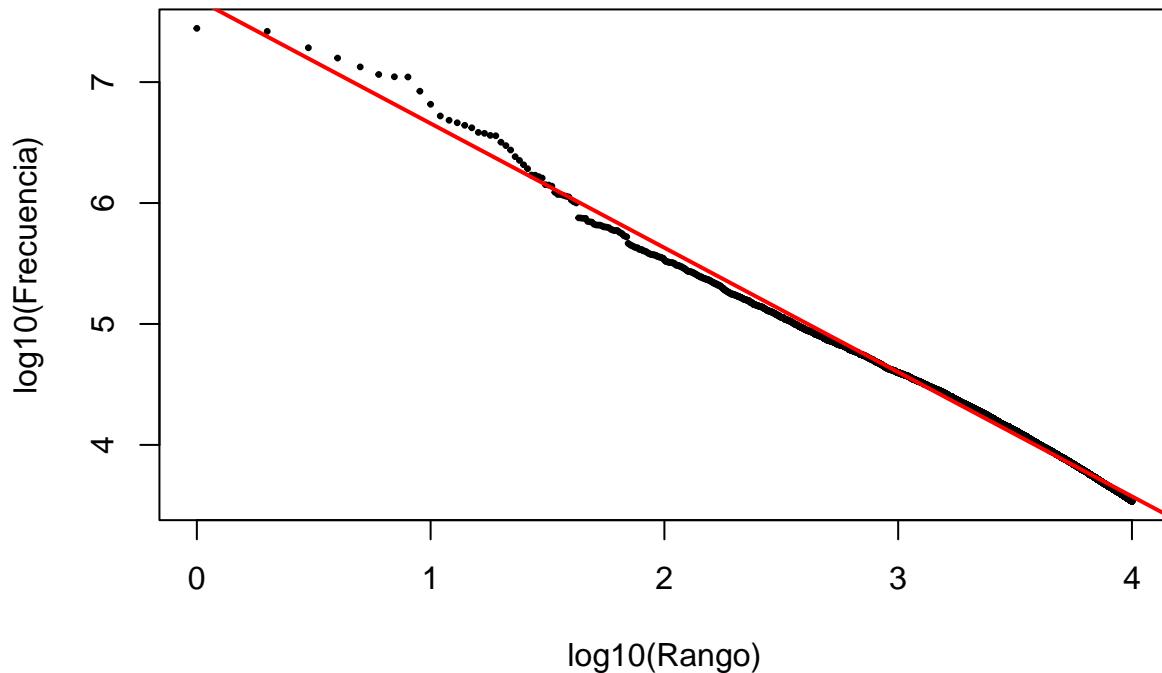
## APARTADO 1
# Creamos la columna de rangos
tabla$rango <- 1:nrow(tabla)

# Gráfico log-log
plot(log10(tabla$rango),
     log10(tabla$Frecuencia),
     pch = 20, cex = 0.5,
     xlab = "log10(Rango)",
     ylab = "log10(Frecuencia)",
     main = "Ley de Zipf: Frecuencia vs Rango (escala log-log)")

# Ajuste lineal para visualizar la tendencia
modelo <- lm(log10(Frecuencia) ~ log10(rango), data = tabla)
abline(modelo, col = "red", lwd = 2)

```

## Ley de Zipf: Frecuencia vs Rango (escala log-log)



### Apartado 1.1

```
## Apartado 1.1
# 1.1.1) BUSCAR FORMAS REPETIDAS

duplicadas <- tabla$Forma[duplicated(tabla$Forma)]
duplicadas

## character(0)

# 1.1.2) SI HAY DUPLICADAS, MOSTRAR DETALLES

if (length(duplicadas) > 0) {

  lista_repetidas <- lapply(duplicadas, function(f) {
    indices <- which(tabla$Forma == f)
    data.frame(
      Forma = f,
      Linea = indices,
      Frecuencia = tabla$Frecuencia[indices]
    )
  })
}
```

```

resultado <- do.call(rbind, lista_repetidas)
resultado

} else {
  print("No hay formas repetidas en este listado."}

```

```
## [1] "No hay formas repetidas en este listado."
```

## Apartado 1.2

```

## Apartado 1.2

# Pasar todo a minúsculas
tabla$min_forma <- tolower(tabla$Forma)

# Contar cuántas formas básicas tienen variantes
conteo <- table(tolower(tabla$Forma))
duplicados <- conteo[conteo > 1]

cat("Formas básicas con duplicados no exactos:", length(duplicados), "\n")

## Formas básicas con duplicados no exactos: 760

# Mostrar primeros 5 ejemplos
cat("\nPrimeros 5 ejemplos:\n")

## 
## Primeros 5 ejemplos:

for (i in 1:5) {
  forma <- names(duplicados)[i]
  variantes <- unique(tabla$Forma[tolower(tabla$Forma) == forma])
  cat(i, " ", forma, " con las variantes: ", paste(variantes, collapse = ", "), "\n", sep = ""))
}

## 1 'a' con las variantes: a, A
## 2 'abierto' con las variantes: abierto, Abierto
## 3 'acá' con las variantes: acá, Acá
## 4 'academia' con las variantes: Academia, academia
## 5 'acaso' con las variantes: acaso, Acaso

```

## Apartado 1.3

```

library(stringi)
#Normalización
formas_norm <- stri_trans_nfc(tabla$Forma) # normaliza acentos
formas_norm <- gsub("\u00A0", " ", formas_norm)

```

```

formas_norm <- gsub("\t", " ", formas_norm)

# Función para detectar si la palabra contiene carácter no español
tiene_no_espanoles <- function(texto) {
  grepl("[^A-Za-zñÁéíóúÁÉÍÓÚüÜ .,:¡!¿?---]", texto)
}

no_español <- tiene_no_espanoles(formas_norm)

# Número de palabras con caracteres no españoles (según nuestro criterio)
num_no_español <- sum(no_español)
cat("El nº de formas no españolas según nuestro criterio es: ", num_no_español)

```

## El nº de formas no españolas según nuestro criterio es: 223

```
#Ejemplos
head(tabla$Forma[no_español], 20)
```

```
## [1] "\n\n\n)" "( "»" «" "!" "1" "2" "" """ "3" "4" "10" "5" "6"
## [16] "20" "15" "7" "12" "30"
```

## 2º Parte

### Lectura del archivo 10000 palabras

```

# Leer el archivo
lineas2 <- readLines("frecuencia_formas_ortograficas_1_3.txt",
                      encoding = "UTF-8")
lineas2[0:4]

## [1] "Forma\tFrecuencia\tFrec. norm." ",\t27823866\t56483.65"
## [3] "de\t26286396\t53362.52"      ".\t19226627\t39030.88"

# Buscar donde empieza la primera linea
linea_inicio2 <- grep("^[^0-9\t\n]+", lineas2)[1]

# Extraer todas las líneas a partir del inicio
datos2 <- lineas2[linea_inicio2:(linea_inicio2 + length(lineas2)-2)] #El -2 pq sinó aparecen 2 líneas v

# Separar cada línea por tabulador (\t)
partes2 <- strsplit(datos2, "\t")
partes2[0:4]

## [[1]]
## [1] "27823866" "56483.65"
##
## [[2]]
## [1] "26286396" "53362.52"
```

```

## [[3]]
## [1] " ."           "19226627" "39030.88"
##
## [[4]]
## [1] "la"          "15799962" "32074.6"

# Extraer las columnas
formas2 <- sapply(partes2, function(x) x[1])
frecuencias2 <- as.numeric(sapply(partes2, function(x) x[2]))
frec_norm2 <- as.numeric(sapply(partes2, function(x) x[3]))

# Crear el dataframe
tabla2 <- data.frame(Forma = formas2,
                      Frecuencia = frecuencias2,
                      Frec.norm = frec_norm2,
                      stringsAsFactors = FALSE)
head(tabla2)

##    Forma Frecuencia Frec.norm
## 1      ,     27823866   56483.65
## 2    de     26286396   53362.52
## 3    .     19226627   39030.88
## 4    la     15799962   32074.60
## 5    que    13350795   27102.69
## 6    y     11562228   23471.82

tail(tabla2)

##                               Forma Frecuencia Frec.norm
## 1484611                  Paulitz        1        0
## 1484612                 Paulitis       1        0
## 1484613                Paulist o       1        0
## 1484614               Paulistana      1        0
## 1484615                 Paulist       1        0
## 1484616 pauljohnsonesco      1        0

```

## Apartado 2.3

```

library(stringi)

# Normalización
formas_norm2 <- stri_trans_nfc(tabla2$Forma) # normaliza acentos
formas_norm2 <- gsub("\u00AO", " ", formas_norm2)
formas_norm2 <- gsub("\t", " ", formas_norm2)

# Función para detectar si la palabra contiene carácter no español
tiene_no_espanoles <- function(texto) {
  grepl("[^A-ZáéíóúÁÉÍÓÚüÜ .,:!¿?---]", texto)
}

```

```

no_espanol2 <- tiene_no_espanoles(formas_norm2)

# Número de palabras con caracteres no españoles (según nuestro criterio)
num_no_espanol2 <- sum(no_espanol2)
cat("El nº de formas no españolas según nuestro criterio es: ", num_no_espanol2)

## El nº de formas no españolas según nuestro criterio es: 77639

#Ejemplos
head(tabla2$Forma[no_espanol2], 20)

## [1] "\" " )" "( " »" "«" "" "1" "2" "" " " "3" "4" "10" "5" "6"
## [16] "20" "15" "7" "12" "30"

tail(tabla2$Forma[no_espanol2], 20)

## [1] "Pathology®"      "pâtissiére"      "pâtissiere"
## [4] "pâtisseries"     "PÂTISSERIE"     "patísserie"
## [7] "pâtiserie"       "patológicos3"    "Patrão"
## [10] "Pâtria"          "Pâtre"          "PÂTRICIA"
## [13] "patrilla$$$thrilla" "Patrimônio"    "Patrimonio18"
## [16] "patronos198"     "patrono58"      "PATT27"
## [19] "Paulão"          "paulavives12"   "paulavives12"

#tabla2$Forma[no_espanol2]

```